Rapport d'analyse et de modélisation – Détection du churn client

1. Présentation de l'algorithme sélectionné et justification du choix

Contexte et objectif

L'objectif du projet est de prédire le churn client à partir de données comportementales, démographiques et transactionnelles. Cette capacité prédictive permet aux entreprises de mettre en place des stratégies de rétention ciblées et d'optimiser l'allocation des ressources marketing[1].

Méthodologie de sélection du modèle

Plusieurs modèles ont été testés : Régression Logistique, Support Vector Machine (SVM) et Random Forest. Pour garantir une comparaison équitable, chaque modèle a été intégré dans un pipeline complet comprenant :

- Imputation des valeurs manquantes
- Encodage des variables catégorielles
- Normalisation des variables numériques
- Rééchantillonnage via SMOTE pour corriger le déséquilibre des classes
- Entraînement du modèle

La sélection du meilleur modèle s'est appuyée sur une validation croisée (CV) à 5 folds, en évaluant trois métriques essentielles[2] :

- **Recall** : capacité à identifier les clients réellement en risque de churn
- **Accuracy** : performance globale du modèle

- **F1-score** : équilibre entre précision et rappel

Justification du choix du Random Forest

Le Random Forest a été sélectionné comme modèle final pour les raisons suivantes[3] :

- Il obtient les meilleurs scores sur les trois métriques en validation croisée
- Il capture efficacement les interactions non linéaires entre variables
- Il est robuste aux données bruitées et aux variables fortement corrélées
- Il gère bien les datasets tabulaires, typiques des problématiques de churn
- Il présente un excellent compromis entre précision et rappel, essentiel pour limiter les pertes de clients

2. Modèle entraîné et résultats de l'évaluation finale

Performances sur le jeu de test

Après sélection, le Random Forest a été réentraîné sur l'ensemble du jeu d'entraînement, puis évalué sur le jeu de test. Les performances obtenues sont synthétisées dans le tableau suivant :

Métrique	Valeur
Accuracy	94,5%
Precision	94,9%
Recall	74,2%
F1-score	0,83
AUC-ROC	0,985

Table 1: Performances du Random Forest sur le jeu de test

Interprétation des résultats

Les performances obtenues témoignent de l'excellente qualité du modèle :

- **Accuracy de 94,5%** : indique une excellente performance globale, avec une très faible proportion d'erreurs.
- **Precision de 94,9%** : le modèle génère très peu de fausses alertes. Lorsqu'il prédit un churn, il a presque toujours raison, limitant le gaspillage de ressources marketing sur des clients non à risque.
- **Recall de 74,2%** : détecte environ trois churners sur quatre, ce qui est très bon dans un contexte de classes déséquilibrées[1]. Cet équilibre permet de cibler la plupart des clients à risque sans surcharger les équipes opérationnelles.
- **F1-score de 0,83** : confirme un bon équilibre entre précision et rappel, deux dimensions critiques en churn prediction.
- **AUC-ROC de 0,985** : indique une capacité quasi parfaite à distinguer churners et non-churners, et démontre que le modèle est efficace quel que soit le seuil de décision appliqué[2].

Analyse de la matrice de confusion

L'analyse détaillée des prédictions révèle que le modèle :

- Identifie très bien les non-churners (99,1% de vrais négatifs), minimisant les fausses alarmes coûteuses
- Détecte la majorité des churners (74,2% de vrais positifs), permettant une intervention ciblée
- Commet très peu de fausses alertes (10 faux positifs), confirmant la fiabilité opérationnelle

Importance des variables

Les variables les plus influentes pour la prédiction du churn incluent :

- LoginFrequency : l'engagement numérique est un signal majeur
- Age : le profil démographique influe sur le comportement de rétention
- AmountSpent : le volume d'achat antérieur est prédictif

- ServiceUsage_Website et ServiceUsage_Online Banking : l'utilisation des canaux numériques
- IncomeLevel : le niveau de revenus module le risque de churn
- ProductCategory (Clothing, Electronics, Books, Furniture) : certaines catégories attirent des clients moins fidèles
- MaritalStatus et Gender : profils socio-démographiques
- Certaines valeurs manquantes : révélatrices de comportements atypiques ou de désengagement

Ces résultats indiquent que le churn est fortement lié à l'engagement numérique, aux habitudes d'achat, aux profils démographiques et socio-économiques[3].

3. Recommandations pour l'utilisation du modèle en entreprise

Utilisation opérationnelle des prédictions

Le modèle peut être intégré dans plusieurs processus clés pour maximiser son impact métier :

- **Segmentation des clients à risque** : identifier les clients ayant une probabilité élevée de churn pour cibler des actions de rétention prioritaires
- **Campagnes marketing personnalisées** : proposer des offres et messages adaptés aux segments les plus susceptibles de partir
- **Optimisation du service client** : prioriser les clients à risque dans les interactions (support proactif, enquêtes de satisfaction)
- **Suivi en temps réel** : intégrer le modèle dans un tableau de bord pour surveiller l'évolution du churn et ajuster les stratégies
- **Allocation des ressources** : concentrer les budgets de rétention sur les clients générant le plus de valeur identifiés comme à risque

Actions business possibles

1. Offrir des réductions ciblées aux clients à forte probabilité de churn, en ajustant le montant en fonction de leur lifetime value potentielle

2. Améliorer l'expérience utilisateur pour les segments identifiés comme sensibles, notamment ceux avec faible LoginFrequency
3. Développer des programmes de fidélité personnalisés pour les groupes démographiques identifiés comme à risque
4. Analyser les catégories de produits associées au churn pour ajuster l'offre commerciale
5. Mettre en place des alertes automatisées pour déclencher des actions de rétention dès qu'un client dépasse un seuil de probabilité de churn
6. Enrichir les profils clients avec les prédictions du modèle pour une meilleure segmentation marketing

Critères de décision d'intervention

Pour optimiser le ROI des campagnes de rétention, il est recommandé de :

- Définir un seuil de probabilité de churn déclenchant une action (ex. : >50% pour une intervention légère, >75% pour une offre spéciale)
- Calculer le coût de rétention comparé à la valeur du client potentiellement perdu
- Adapter les actions selon le segment (clients à haute valeur vs clients d'acquisition récente)
- Tester différentes stratégies de rétention via A/B testing pour mesurer l'efficacité réelle

4. Pistes d'amélioration du modèle

Optimisation des performances

Plusieurs axes peuvent encore améliorer les performances du modèle :

1. **Optimisation des hyperparamètres du Random Forest** : utiliser GridSearch, RandomSearch ou Bayesian Optimization pour affiner les paramètres du modèle
2. **Test de modèles avancés** : explorer XGBoost, LightGBM ou CatBoost, souvent très performants sur données tabulaires[4]
3. **Ajustement du seuil de décision** : augmenter le recall si l'objectif prioritaire est de réduire au maximum les churners

non détectés
4. **Stacking et ensembles** : combiner plusieurs modèles pour capturer différentes dimensions du phénomène de churn

Enrichissement des données

- Collecte de nouvelles données comportementales : historique de support client, satisfaction (NPS), patterns de navigation détaillés
- Intégration de données externes : scores de crédit, données géolocalisées, données de marché
- Création de nouvelles variables : ratio d'activité (LoginFrequency / AmountSpent), tendances temporelles (accélération ou ralentissement des achats)
- Analyse approfondie des variables actuelles pour identifier des leviers business supplémentaires

Mise en production et monitoring

- Déploiement progressif du modèle avec suivi des performances en environnement réel
- Mise en place d'une évaluation régulière (mensuelle ou trimestrielle) du modèle pour détecter une dégradation des performances (data drift)
- Réentraînement automatique du modèle avec les nouvelles données de churn observées
- Suivi des métriques métier associées : taux de rétention effectif, ROI des campagnes, coût de rétention par client

5. Conclusion

Ce rapport démontre que le Random Forest est un modèle particulièrement adapté à la détection du churn client, combinant excellence prédictive (AUC-ROC 0,985) et praticité opérationnelle. Ses performances équilibrées (94,5% accuracy, 74,2% recall) permettent une intégration directe dans les processus marketing et de service client.

Au-delà de la simple prédiction, la compréhension des variables influentes offre des opportunités concrètes d'amélioration de la rétention : optimisation de l'engagement numérique, ajustement de l'offre produit, et personnalisation des stratégies selon le profil client.

La mise en œuvre progressive du modèle, accompagnée d'un suivi régulier et d'ajustements basés sur les résultats métier réels, permettra à l'entreprise de transformer ses données en avantage compétitif durable.

Références

[1] FasterCapital (2025). Evaluation Metrics For Churn Prediction Models. https://fastercapital.com/topics/evaluation-metrics-for-churn-prediction-models.html

[2] Kaggle (2024). Customer Churn Prediction Challenge. https://kaggle.com/competitions/churn-competition-pdc

[3] Guru99 (2024). Tutoriel R Random Forest avec exemple. https://www.guru99.com/fr/r-random-forest-tutorial.html

[4] FastData Science (2026). Predicting Customer Churn using Machine Learning and AI. https://fastdatascience.com/ai-for-business/predict-customer-churn-machine-learning-ai/